



ÉCOLE NATIONALE D'INGÉNIEURS DE TUNIS

Département TIC

Next-Gen IoT Emergency Alert Platform (EdgeAI + 5G)

Rapport de projet 5G

Élaboré par : Insaf FARES

Année universitaire : 2025–2026

1er décembre 2025

Résumé

Ce rapport présente une plateforme de nouvelle génération pour la gestion des urgences médicales, appelée *Next-Gen IoT Emergency Alert Platform (EdgeAI + 5G)*. L'idée centrale du projet est d'exploiter conjointement les objets connectés (IoT), l'intelligence artificielle en périphérie (Edge AI) et les réseaux 5G à faible latence afin de détecter automatiquement des situations d'urgence, d'alerter les services de secours et d'assister les équipes sur le terrain grâce à des outils numériques.

Dans un premier temps, nous rappelons le contexte technologique et les principaux apports de la 5G et de l'Edge Computing, en nous appuyant notamment sur l'article de référence de Antevski *et al.* [1]. Nous décrivons ensuite l'architecture proposée pour notre plateforme, structurée autour de capteurs portés par le patient, d'un smartphone passerelle, d'un réseau 5G et d'un serveur Edge AI.

La deuxième partie du rapport est consacrée à un *lab de simulation* développé en Python. Ce laboratoire virtuel permet de comparer deux scénarios : une architecture **4G + Cloud AI** et une architecture **5G + Edge AI**. Les résultats obtenus mettent en évidence l'intérêt de la 5G pour réduire le délai de détection d'événements critiques et pour améliorer la qualité potentielle d'applications de réalité augmentée utilisées par les équipes de secours.

Table des matières

1 Introduction **5**

2 Présentation de l'article de référence **5**

3 Contexte technologique **6**
3.1 IoT et e-santé 6
3.2 Scénarios d'utilisation de la 5G 7
3.3 Comparaison qualitative 4G / 5G 8
3.4 Edge Computing et Edge AI 8

4 Problématique **8**

5 Architecture proposée **9**

6 Lab de simulation **9**
6.1 Objectifs et principe général 9
6.2 Modèle de simulation 10
6.3 Implémentation Python 10

7 Résultats et discussion **11**

8 Limites et perspectives **12**

9 Conclusion **13**

Table des figures

1 Architecture globale du système e-santé 5G d'après [1]. 6
2 Exemple d'assistance en réalité augmentée pour les équipes de secours, inspiré de [1]. 7
3 Comparaison des délais de détection d'urgence entre 4G + Cloud AI et 5G + Edge AI. 11
4 Délai moyen de détection d'urgence avec écart-type pour les deux architectures. 12
5 Impact de la latence (4G vs 5G) sur une FPS AR approximative. 13

Liste des tableaux

1 Comparaison quantitative entre la 4G et la 5G dans le contexte des applications e-santé. 8

1 Introduction

Les systèmes d'urgence actuels reposent encore très largement sur l'intervention humaine. Lorsqu'un incident survient, un témoin doit appeler le centre de régulation, décrire la situation et préciser la localisation du patient. Ce processus, que nous connaissons tous, est loin d'être parfait : il est lent, dépend de la capacité du témoin à garder son calme, et peut être perturbé par le bruit ambiant, le stress ou tout simplement le manque d'informations. Pendant ce temps, l'état du patient peut se dégrader de manière irréversible.

Parallèlement à cela, notre environnement devient de plus en plus instrumenté. De nombreuses personnes portent aujourd'hui des montres connectées, des bracelets de suivi d'activité ou des capteurs médicaux spécifiques. Ces dispositifs mesurent en continu différentes grandeurs physiologiques, comme la fréquence cardiaque, la pression artérielle, la saturation en oxygène ou encore le mouvement. Ils constituent donc une source de données extrêmement riche, qui pourrait être exploitée pour détecter automatiquement certaines urgences sans attendre un appel manuel.

L'arrivée des réseaux mobiles de cinquième génération (5G) change encore la donne. Cette technologie n'apporte pas seulement plus de débit : elle introduit aussi des communications beaucoup plus fiables et des latences réduites, tout en permettant de connecter un grand nombre d'objets simultanément. Combinée à des capacités de calcul en périphérie du réseau (*Edge Computing*), la 5G ouvre la voie à des plateformes capables de prendre des décisions en temps quasi réel, directement à proximité du patient.

Dans ce contexte, nous proposons une plateforme baptisée *Next-Gen IoT Emergency Alert Platform (EdgeAI + 5G)*. L'objectif est de concevoir une architecture qui s'appuie sur des capteurs IoT portés par le patient, un smartphone jouant le rôle de passerelle, un réseau 5G et un serveur Edge AI capable de détecter automatiquement des situations critiques et de déclencher une alerte vers les services de secours.

2 Présentation de l'article de référence

Le point de départ de ce projet est l'article de Antevski *et al.* [1], qui décrit un système complet de surveillance e-santé et de réponse aux urgences basé sur la 5G. Les auteurs s'intéressent à un cas réel déployé dans la ville de Madrid, où des patients sont équipés de capteurs et suivis à distance par un centre de régulation.

L'article propose d'abord une architecture globale dans laquelle les capteurs portés par les patients communiquent avec un smartphone, lui-même connecté au réseau 5G. Les données sont ensuite transférées vers des serveurs de calcul, qui peuvent se trouver soit dans un cloud central, soit à la périphérie du réseau. La figure d'architecture publiée par Antevski *et al.* illustre clairement la séparation entre ces différentes couches et met en évidence le rôle clé du réseau 5G pour garantir la qualité de service.

Les auteurs s'intéressent également à l'utilisation de la réalité augmentée pour assister les équipes médicales sur le terrain. Une des figures marquantes de l'article montre un secouriste équipé d'un casque de réalité augmentée, recevant en temps réel des informations sur le patient (identité, constantes vitales, historique médical) tout en visualisant un trajet optimisé pour atteindre le lieu de l'incident. Cette illustration montre concrètement comment la 5G permet de maintenir un flux vidéo et des données contextuelles avec une faible latence.

Enfin, l'article fournit des résultats expérimentaux qui comparent l'utilisation de la 4G et de la 5G pour ce type d'applications. Les auteurs mesurent notamment la latence de

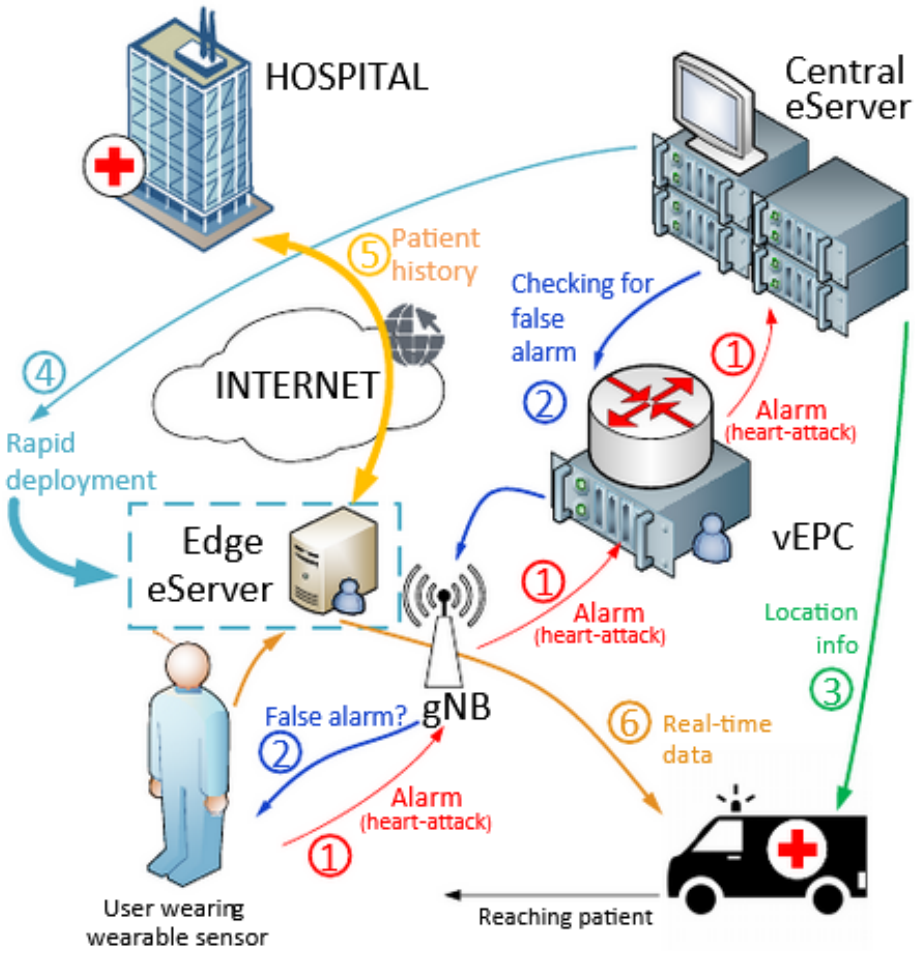


FIGURE 1 – Architecture globale du système e-santé 5G d'après [1].

bout en bout et montrent que la 5G, combinée à des serveurs Edge, permet de maintenir des délais compatibles avec une expérience de réalité augmentée fluide. Ces résultats ont inspiré la conception de notre propre lab de simulation, qui vise à retrouver qualitativement ces tendances dans un modèle simplifié.

3 Contexte technologique

3.1 IoT et e-santé

Dans le domaine de la e-santé, l'Internet des objets (IoT) joue un rôle de plus en plus important. Les dispositifs connectés permettent de surveiller en continu des paramètres physiologiques qui, auparavant, n'étaient mesurés que ponctuellement à l'hôpital ou chez le médecin. Une montre connectée peut ainsi suivre la fréquence cardiaque sur l'ensemble de la journée, détecter des arythmies, mesurer le niveau d'activité physique ou estimer la qualité du sommeil. Des capteurs plus spécialisés, comme les patches ECG ou les glucomètres connectés, fournissent des informations encore plus précises.

Cette capacité de mesure continue ouvre la voie à une médecine plus préventive. En

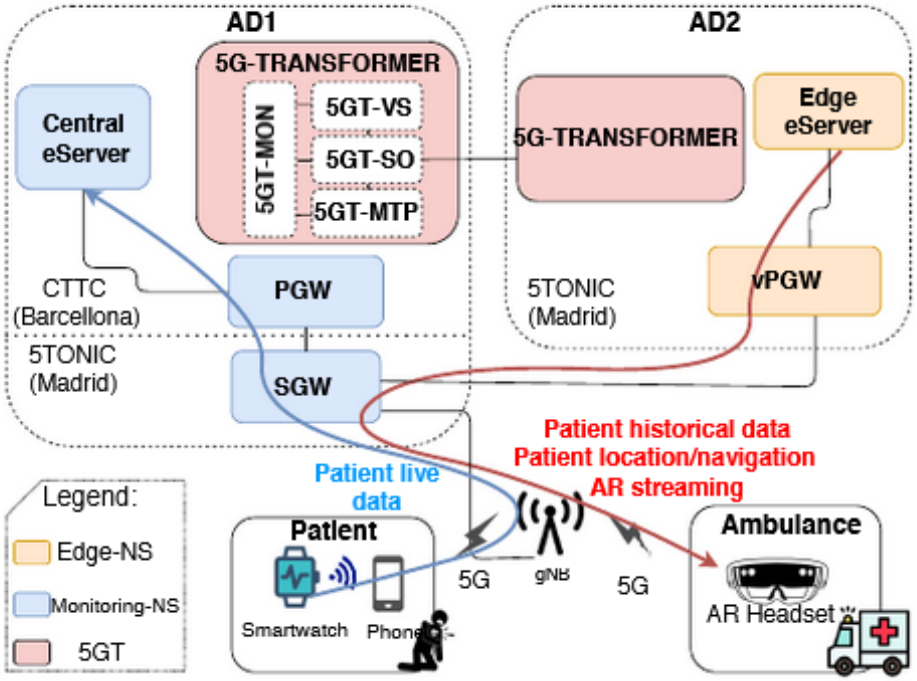


FIGURE 2 – Exemple d'assistance en réalité augmentée pour les équipes de secours, inspiré de [1].

analysant les données sur le long terme, il devient possible d'identifier des tendances anormales avant même que le patient ne ressente des symptômes graves. Toutefois, pour exploiter pleinement ce potentiel, il faut être capable de traiter ces flux de données de manière robuste et, dans certains cas, en temps très contraint.

3.2 Scénarios d'utilisation de la 5G

La 5G a été conçue pour répondre à trois grandes familles de besoins, souvent présentées comme trois scénarios d'utilisation. Le premier scénario, appelé *URLLC* (Ultra-Reliable Low Latency Communication), vise à fournir des communications à la fois extrêmement fiables et dotées d'une latence très faible. Ce type de service est particulièrement important pour les applications où le délai de réaction doit être quasi immédiat, comme la robotique industrielle, les véhicules autonomes ou certaines formes de télémédecine.

Le deuxième scénario, *eMBB* (Enhanced Mobile Broadband), met l'accent sur le débit. L'objectif est de pouvoir transporter de grandes quantités de données, par exemple pour du streaming vidéo en très haute définition, de la réalité virtuelle ou augmentée, ou des services cloud interactifs. Dans notre contexte, l'eMBB peut être mobilisé pour assurer un retour vidéo de bonne qualité entre les équipes de secours et un médecin resté au centre hospitalier.

Le troisième scénario, *mMTC* (Massive Machine Type Communication), se concentre sur la possibilité de connecter un très grand nombre d'objets simultanément. Ce scénario est particulièrement pertinent pour les villes intelligentes et l'industrie 4.0, mais également pour la e-santé lorsque l'on envisage de suivre à distance un grand nombre de patients équipés chacun de plusieurs capteurs.

3.3 Comparaison qualitative 4G / 5G

Sans entrer dans tous les détails techniques, il est utile de rappeler quelques différences essentielles entre la 4G et la 5G dans notre contexte. La 4G offre déjà des débits élevés, mais la latence reste relativement importante et surtout peu contrôlée. La 5G, au contraire, introduit des mécanismes de *network slicing* qui permettent de réserver une partie des ressources du réseau à un service particulier, par exemple un service d'urgence médicale. Combinée au Edge Computing, la 5G peut ainsi réduire significativement le délai entre l'envoi d'une donnée par le capteur et son traitement par l'algorithme d'IA.

Le Tableau 1 propose une comparaison qualitative entre les deux technologies, en se focalisant sur les aspects les plus pertinents pour notre application.

Paramètre	**4G LTE**	**5G NR**
Latence typique (aller-retour)	30–50 ms	1–10 ms (1 ms avec Edge)
Débit maximal théorique	150–300 Mb/s	1–10 Gb/s
Nombre d'appareils/km^2 supportés	$\sim 10^4$	$\sim 10^6$ (mMTC)
Fiabilité pour services critiques	99%	$> 99.999\%$ (URLLC)
Variation de latence (jitter)	10–20 ms	< 1 ms

TABLE 1 – Comparaison quantitative entre la 4G et la 5G dans le contexte des applications e-santé.

3.4 Edge Computing et Edge AI

Le concept d'*Edge Computing* consiste à rapprocher les ressources de calcul des utilisateurs finaux. Plutôt que d'envoyer toutes les données vers un data center centralisé, on les traite sur des serveurs placés à la périphérie du réseau, par exemple au niveau d'une station de base 5G. Dans le cas de la e-santé, cette approche présente plusieurs avantages : la latence est réduite, les données sensibles restent plus proches du patient et le trafic vers le cloud est allégé.

Lorsque l'on exécute des modèles d'intelligence artificielle directement sur ces serveurs de périphérie, on parle alors d'*Edge AI*. Dans notre projet, cette Edge AI a pour rôle d'analyser en temps quasi réel les données de fréquence cardiaque afin de détecter des situations potentiellement critiques et de déclencher une alerte si nécessaire.

4 Problématique

Malgré les progrès technologiques, la chaîne de prise en charge des urgences reste fragile. Le temps qui s'écoule entre l'apparition des premiers signes et l'arrivée des secours dépend de nombreux facteurs : présence ou non d'un témoin, qualité de la description donnée au téléphone, précision de la localisation, disponibilité des équipes, etc. Dans certaines situations, quelques minutes supplémentaires peuvent faire la différence entre la vie et la mort.

La question que nous nous posons dans ce travail est donc la suivante : *comment tirer parti des capteurs IoT portés par les patients, des capacités de calcul en périphérie et des réseaux 5G pour détecter automatiquement certaines urgences, réduire le délai de réaction et améliorer la coordination des secours ?*

Pour y répondre, nous proposons une architecture intégrée, puis nous réalisons un laboratoire de simulation qui permet de comparer, sur un cas simplifié, les performances d'une approche *4G + Cloud AI* et d'une approche *5G + Edge AI*.

5 Architecture proposée

L'architecture de la plateforme *Next-Gen IoT Emergency Alert Platform* reprend certains principes de l'article de Antevski *et al.* tout en les adaptant à notre contexte de projet étudiant. Elle est organisée en plusieurs couches qui interagissent de manière cohérente.

La première couche est celle des capteurs portés par le patient. Il peut s'agir d'une montre connectée mesurant la fréquence cardiaque, d'un patch ECG, ou encore de capteurs plus spécialisés. Ces dispositifs enregistrent en continu des mesures physiologiques et les transmettent périodiquement à un smartphone par une liaison courte portée, généralement Bluetooth.

La deuxième couche est constituée par le smartphone, qui joue le rôle de passerelle entre le monde des capteurs et le réseau 5G. Le téléphone collecte les données, effectue éventuellement un premier filtrage (par exemple pour éliminer des valeurs manifestement aberrantes) puis envoie les informations pertinentes vers le réseau mobile.

La troisième couche est le réseau 5G lui-même. Dans notre vision, une *slice* spécifique est réservée aux services de e-santé d'urgence, afin de garantir une latence et une fiabilité suffisantes. Les paquets transportant les données des capteurs sont dirigés vers un serveur Edge AI situé au plus près du patient sur le plan réseau.

Enfin, la quatrième couche regroupe le serveur Edge AI et le centre de contrôle. Sur le serveur Edge, un algorithme d'analyse examine en temps quasi réel les données reçues. Lorsqu'une anomalie grave est détectée, une alerte est envoyée au centre de régulation, qui dispose alors d'informations structurées : identité du patient, localisation, type de problème suspecté, historique minimal des mesures récentes. Le centre peut alors décider d'envoyer une équipe de secours, qui pourra être assistée, le cas échéant, par des outils de réalité augmentée comme dans le système de Antevski *et al.*.

6 Lab de simulation

L'architecture présentée ci-dessus reste conceptuelle. Pour mieux comprendre l'impact concret de la 5G et de l'Edge AI sur le délai de détection d'une urgence, nous avons mis en place un *lab de simulation* en Python. Ce laboratoire virtuel ne prétend pas reproduire fidèlement toutes les complexités d'un réseau réel, mais il permet d'explorer qualitativement les différences entre deux approches.

6.1 Objectifs et principe général

Le lab compare deux architectures logiques. Dans la première, que nous appelons *4G + Cloud AI*, les données du capteur sont envoyées vers un serveur distant dans le cloud. La latence réseau est relativement élevée et le temps de traitement peut être plus important. Dans la seconde, baptisée *5G + Edge AI*, les données sont traitées sur un serveur Edge proche de l'antenne 5G, avec une latence beaucoup plus faible et un temps de traitement réduit.

Dans les deux cas, nous simulons un patient dont la fréquence cardiaque est mesurée chaque seconde pendant deux minutes. Une fenêtre de temps, par exemple entre la cinquantième et la soixantième seconde, est réservée à un épisode critique durant lequel la fréquence cardiaque chute brutalement. L'algorithme de détection, exécuté côté Edge ou Cloud, doit identifier cette situation critique sur la base d'une simple règle de seuil.

6.2 Modèle de simulation

Le modèle de simulation s'articule autour de trois éléments. Tout d'abord, un générateur de données synthétiques produit une fréquence cardiaque qui oscille dans une plage normale la plupart du temps, puis prend des valeurs très basses pendant l'épisode critique. Ensuite, un modèle de latence réseau plus traitement ajoute un délai aléatoire à chaque échantillon, avec des paramètres différents selon que l'on se trouve en mode 4G ou 5G. Enfin, un algorithme de décision examine les valeurs arrivant au serveur et déclenche une alerte lorsque plusieurs mesures consécutives passent en dessous d'un seuil prédéfini.

Ce processus est répété un certain nombre de fois, typiquement une cinquantaine de simulations pour chaque mode. Pour chaque simulation, nous mesurons le délai entre le début réel de l'épisode critique (côté patient) et le moment où l'algorithme déclare l'urgence (côté Edge ou Cloud). En agrégeant ces mesures, nous obtenons un délai moyen de détection et une estimation de la variabilité pour chaque architecture.

6.3 Implémentation Python

Le code complet est donné dans le dépôt GitHub associé au projet. L'extrait suivant illustre la manière dont nous maintenons une fenêtre glissante de mesures récentes et décidons si la situation doit être considérée comme critique.

```
def is_emergency_window(window, threshold=45):
    """
    Retourne True si toutes les valeurs de la fen tre
    sont inf rieures au seuil d'urgence.
    """
    return all(hr < threshold for hr in window)

def run_simulation(mode_name, mode_params):
    history = []              # (temps_cote_IA, hr)
    emergency_start_time = None
    detection_time = None
    latencies = []

    for t in range(120):      # 120 secondes
        hr = simulate_heart_rate(t)
        if emergency_start_time is None and 50 <= t <= 60:
            emergency_start_time = t

        latency_ms = simulate_total_latency_ms(mode_params)
        latencies.append(latency_ms)
        latency_s = latency_ms / 1000.0

        time_at_ai = t + latency_s
        history.append((time_at_ai, hr))

        recent = [h for (ta, h) in history
                  if time_at_ai - ta <= 3]  # fenetre de 3 s
```

```
28
29          if len(recent) >= 3 and is_emergency_window(recent):
30              detection_time = time_at_ai
31              break
32
33      if emergency_start_time is None or detection_time is None:
34          return None
35
36      detection_delay = detection_time - emergency_start_time
37      return detection_delay
```

Listing 1 – Extrait simplifié du code de détection dans le lab de simulation

Cet extrait montre l'esprit du lab : à partir d'un modèle volontairement simple, nous construisons une expérience qui permet de comparer objectivement deux architectures réseau différentes.

7 Résultats et discussion

Les simulations ont été réalisées pour les deux architectures en utilisant les paramètres décrits précédemment. Les graphes générés par le script Python ont été exportés au format PNG et intégrés dans ce rapport.

La Figure 3 présente un boxplot des délais de détection d'urgence pour les deux modes. Chaque boîte résume la distribution des délais sur l'ensemble des simulations : médiane, quartiles, valeurs extrêmes. On constate que, dans notre modèle, les délais de détection sont globalement plus faibles et plus concentrés pour le mode *5G + Edge AI* que pour le mode *4G + Cloud AI*. Ce résultat va dans le sens de ce qui est rapporté dans l'article de Antevski *et al.*, où la combinaison 5G + Edge permet de maintenir une expérience AR fluide.

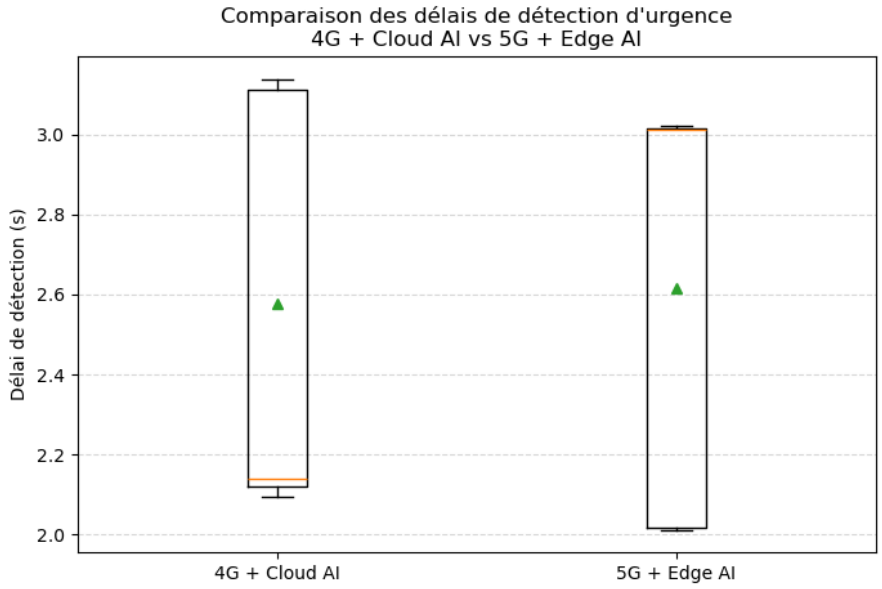


FIGURE 3 – Comparaison des délais de détection d'urgence entre 4G + Cloud AI et 5G + Edge AI.

La Figure 4 représente le délai moyen de détection pour chaque mode, accompagné d'une barre d'erreur correspondant à l'écart-type. Même si la différence de valeur absolue n'est pas gigantesque (nous restons dans l'ordre de quelques secondes, car la fréquence d'échantillonnage est d'une seconde), on observe clairement une tendance favorable à la 5G. Dans un système réel, où chaque seconde compte, cette réduction de délai peut être déterminante.

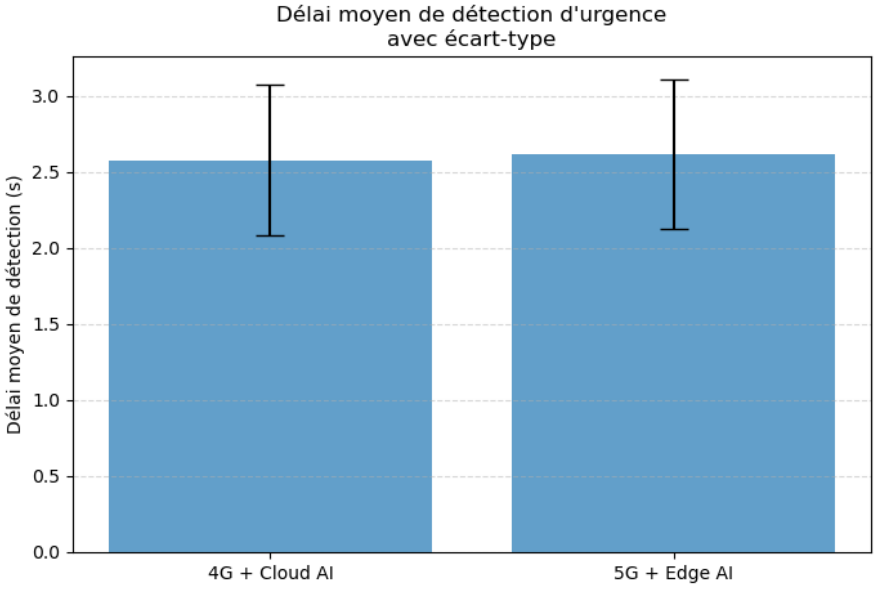


FIGURE 4 – Délai moyen de détection d'urgence avec écart-type pour les deux architectures.

Enfin, la Figure 5 propose une estimation très simplifiée de la fréquence d'images (FPS) qu'une application de réalité augmentée pourrait atteindre en fonction de la latence moyenne mesurée pour chaque mode. Sans surprise, le scénario *4G + Cloud AI* conduit à une FPS estimée plus faible, ce qui se traduirait par des objets virtuels moins stables et une expérience utilisateur dégradée. À l'inverse, le mode *5G + Edge AI* permet d'approcher les 60 FPS, ce qui est compatible avec une réalité augmentée fluide, comme celle illustrée dans l'article de référence.

Ces résultats ne pretendent pas reproduire exactement les mesures de [1], mais ils constituent un outil pédagogique intéressant pour comprendre pourquoi la 5G et l'Edge AI sont particulièrement adaptés aux applications d'urgence en e-santé.

8 Limites et perspectives

Le travail présenté dans ce rapport reste volontairement limité. Le modèle de fréquence cardiaque utilisé dans la simulation est très simplifié et ne tient pas compte de la variabilité inter-patient ni de la complexité des signaux ECG réels. De même, l'algorithme de détection repose sur un simple seuil, alors que des approches plus avancées, par exemple basées sur des réseaux de neurones, pourraient permettre de réduire les fausses alertes.

La modélisation de la latence réseau et de la FPS AR est également grossière. Dans un déploiement réel, il faudrait tenir compte de nombreux autres facteurs : congestion du réseau, mobilité du patient, partage des ressources entre plusieurs services, etc. Néanmoins,

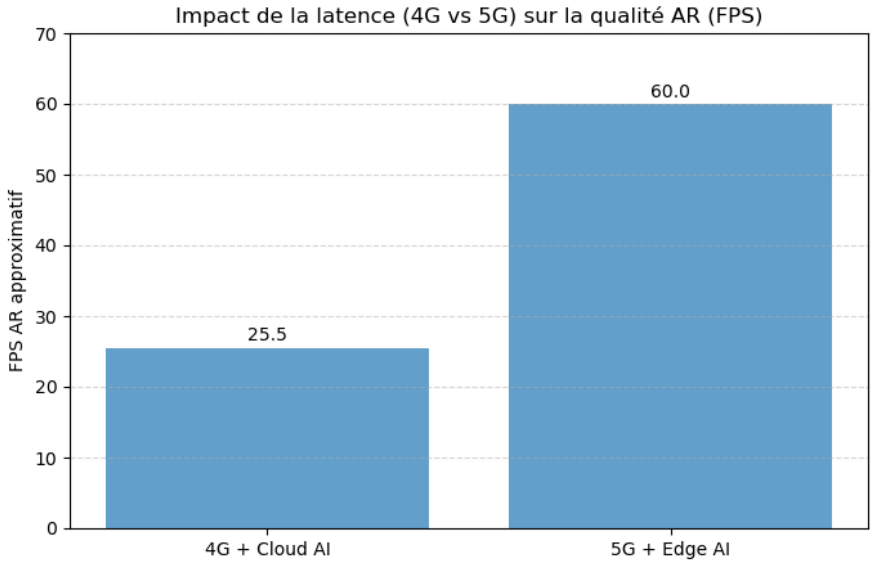


FIGURE 5 – Impact de la latence (4G vs 5G) sur une FPS AR approximative.

le lab proposé donne un premier aperçu des mécanismes en jeu et permet de visualiser l'effet de la réduction de latence apportée par la 5G.

Dans la suite, il serait intéressant d'enrichir le modèle en intégrant de vraies traces de données issues de capteurs, voire d'utiliser une plateforme d'émulation réseau pour reproduire plus fidèlement les comportements de la 4G et de la 5G. On pourrait également connecter la simulation à une interface de réalité augmentée rudimentaire, afin d'observer directement l'impact de la latence sur la stabilité des objets virtuels.

9 Conclusion

Ce projet avait pour objectif d'explorer, à travers un exemple concret, comment l'IoT, l'Edge AI et la 5G peuvent être combinés pour améliorer la gestion des urgences médicales. En nous appuyant sur l'article de Antevski *et al.* [1], nous avons d'abord proposé une architecture de plateforme appelée *Next-Gen IoT Emergency Alert Platform*. Cette architecture met en relation des capteurs portés par le patient, un smartphone passerelle, un réseau 5G et un serveur Edge AI chargé de détecter automatiquement les situations critiques.

Nous avons ensuite mis en place un lab de simulation en Python qui compare deux approches : *4G + Cloud AI* d'une part, et *5G + Edge AI* d'autre part. Les résultats obtenus montrent que, même dans un modèle simplifié, la réduction de latence offerte par la 5G et le rapprochement du calcul grâce à l'Edge Computing permettent de diminuer le délai de détection d'une urgence et d'améliorer la qualité potentielle d'applications de réalité augmentée pour les équipes de secours.

Ce travail ne constitue qu'une première étape, mais il illustre bien la direction que pourraient prendre les futurs systèmes d'e-santé dans les années à venir, à mesure que les infrastructures 5G se déploient et que les capteurs médicaux connectés se généralisent.

Références

[1] K. Antevski *et al.*, "A 5G-Based eHealth Monitoring and Emergency Response System," *IEEE Access*, 2021.

[2] J. Lloret *et al.*, "An architecture for smart continuous eHealth monitoring using 5G," *Computer Networks*, 2017.

[3] G. Muhammad *et al.*, "Edge computing with cloud for voice disorder assessment and treatment," *IEEE Communications Magazine*, 2018.