Analyseur de Sentiments pour les Avis Clients

Projet de Traitement Automatique du Langage Naturel

Réalisé par :
Insaf FARES

Année universitaire : 2025–2026

Table des matières

1 Introduction et Problématique **4**
1.1 Problématique 4
1.2 Objectifs 4

2 Outils et Technologies **5**
2.1 Langage 5
2.2 Bibliothèques 5
2.3 Jeu de données 5

3 Conception du Système **6**
3.1 Architecture Générale 6

4 Réalisation **7**
4.1 Analyse Exploratoire des Données (EDA) 7
4.1.1 Distribution de la longueur des avis 7
4.2 Prétraitement 8
4.3 Baseline : TF-IDF + Régression Logistique 8
4.4 Modèle LSTM 8
4.5 Modèle BERT 9

5 Résultats et Analyse **10**

6 Discussion **11**

7 Conclusion et Perspectives **12**
7.1 Conclusion 12
7.2 Perspectives 12

Table des figures

3.1 Pipeline général du système d'analyse de sentiments 6

4.1 Distribution de la longueur des avis 7
4.2 Densité de la longueur des avis par classe 8
4.3 Matrice de confusion du modèle TF-IDF + LogReg (validation) 8
4.4 Courbe d'apprentissage du modèle LSTM 9

5.1 Comparaison visuelle des performances 10

Liste des tableaux

5.1 Comparaison des performances des modèles 10

Chapitre 1

Introduction et Problématique

Avec l'essor du commerce électronique, les avis clients sont devenus une source stratégique d'information. Ces avis contiennent des indices précieux sur la satisfaction des utilisateurs, mais leur volume rend toute analyse manuelle irréaliste. L'objectif est donc de construire un système capable de classifier automatiquement un avis en sentiment positif ou négatif, puis d'évaluer différentes approches de modélisation.

1.1 Problématique

Comment automatiser l'analyse des avis clients afin d'identifier leur sentiment global de manière fiable et efficace ?

1.2 Objectifs

— Exploiter un jeu de données réel d'avis clients.
— Mettre en œuvre un pipeline NLP complet.
— Comparer des modèles classiques et profonds.
— Analyser les performances et les limites de chaque approche.

Chapitre 2

Outils et Technologies

2.1 Langage

Le projet a été entièrement réalisé en Python.

2.2 Bibliothèques

— **Pandas, NumPy** : manipulation des données
— **Scikit-learn** : TF-IDF et Régression Logistique
— **TensorFlow / Keras** : modèle LSTM
— **PyTorch & Transformers** : modèle BERT
— **Matplotlib / Seaborn** : visualisations

2.3 Jeu de données

Le projet s'appuie sur le jeu de données **Amazon Review Polarity**, composé de millions d'avis annotés en deux classes : positif (notes 4–5) et négatif (notes 1–2), les avis neutres étant exclus. Chaque entrée contient plusieurs champs textuels (titre et contenu), ainsi qu'un label de polarité.

Dans notre préparation, nous avons construit une variable `review` en concaténant les champs `title` et `text`, puis une variable cible binaire `y` (0 : négatif, 1 : positif). L'inspection du dataset montre les colonnes suivantes : `label`, `title`, `text`, `y`, `review`. La distribution des classes est équilibrée (environ 50% positif et 50% négatif), ce qui limite le risque de biais lié au déséquilibre de classes.

Chapitre 3

Conception du Système

3.1 Architecture Générale

Le système suit une architecture modulaire afin de garantir une comparaison équitable entre les modèles. Une même chaîne de prétraitement est appliquée aux textes, puis plusieurs approches de modélisation sont entraînées sur des échantillons comparables. Cette organisation permet d'isoler l'impact du choix de la représentation (TF-IDF vs embeddings) et du type de modèle (linéaire, séquentiel, Transformer) sur la performance.

Le pipeline comprend les étapes suivantes : chargement du dataset, construction de la variable texte (`review`), nettoyage (normalisation et suppression du bruit), séparation entraînement/validation, entraînement des modèles (baseline, LSTM, BERT), puis évaluation via des métriques standard (accuracy, matrice de confusion) et analyse des erreurs.

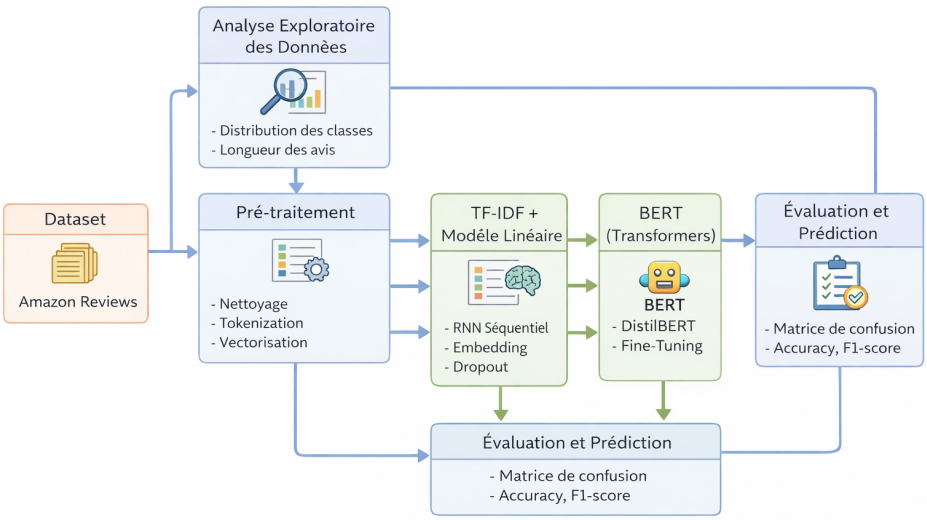


FIGURE 3.1 – Pipeline général du système d'analyse de sentiments

Chapitre 4

Réalisation

4.1 Analyse Exploratoire des Données (EDA)

L'EDA permet de caractériser les textes (taille, variabilité) et de guider les choix de paramétrage des modèles (longueur max, vocabulaire).

4.1.1 Distribution de la longueur des avis

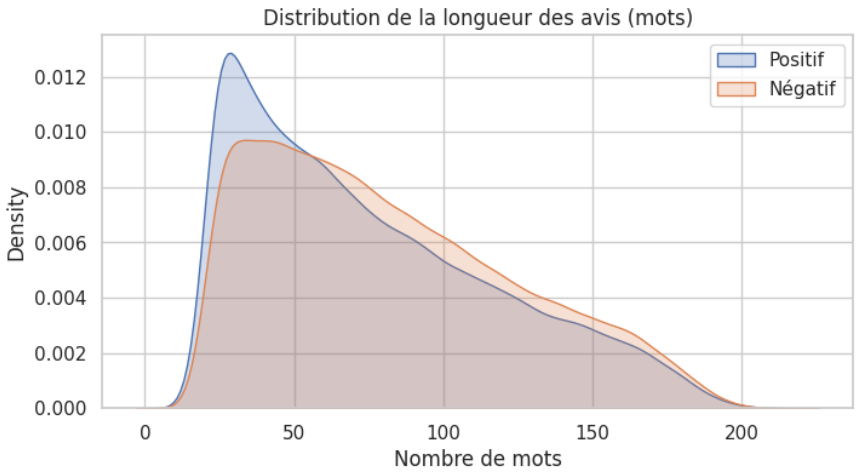


FIGURE 4.1 – Distribution de la longueur des avis

Ces figures montrent que la majorité des avis contiennent moins de 200 mots. La similarité des distributions entre classes indique que la longueur n'est pas discriminante : la classification repose principalement sur le contenu sémantique.

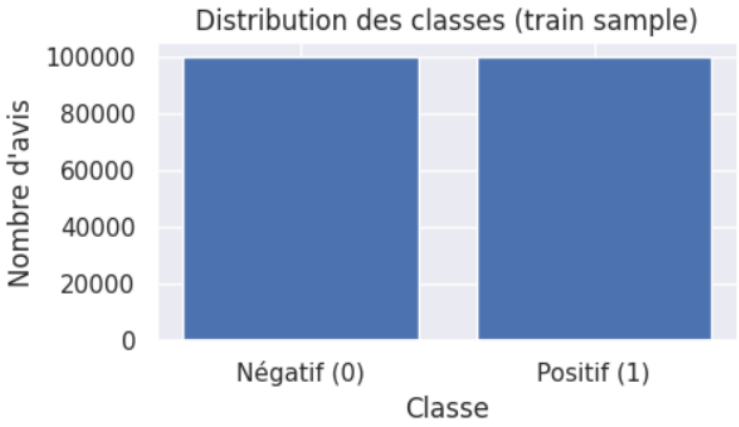


FIGURE 4.2 – Densité de la longueur des avis par classe

4.2 Prétraitement

Le prétraitement vise à réduire le bruit tout en conservant l'information utile. Il inclut la mise en minuscules, la suppression des caractères non alphabétiques et la normalisation des espaces. Ces étapes améliorent la stabilité des modèles et réduisent la variabilité inutile.

4.3 Baseline : TF-IDF + Régression Logistique

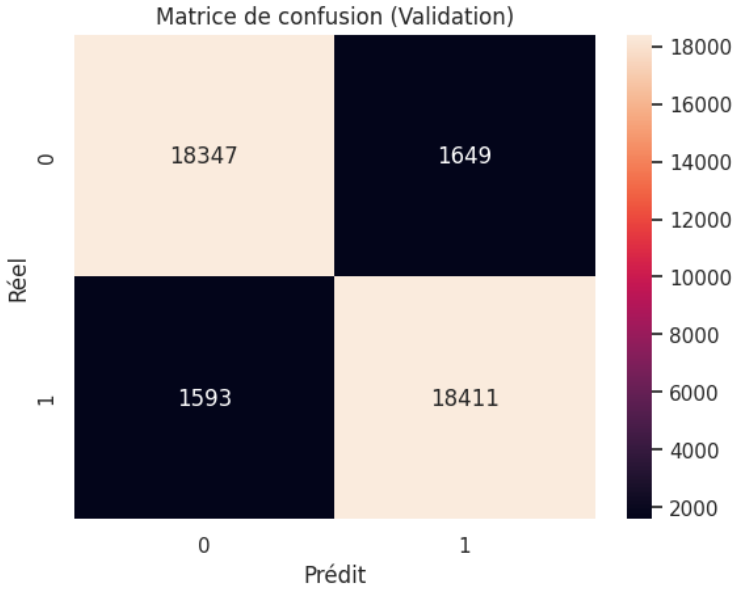


FIGURE 4.3 – Matrice de confusion du modèle TF-IDF + LogReg (validation)

La baseline TF-IDF + LogReg fournit une solution rapide et performante. Les erreurs proviennent principalement d'avis ambigus, ironiques ou contenant des formulations complexes.

4.4 Modèle LSTM

La précision en entraînement augmente fortement alors que la précision en validation plafonne puis diminue légèrement après la première époque. Ce comportement indique un début de

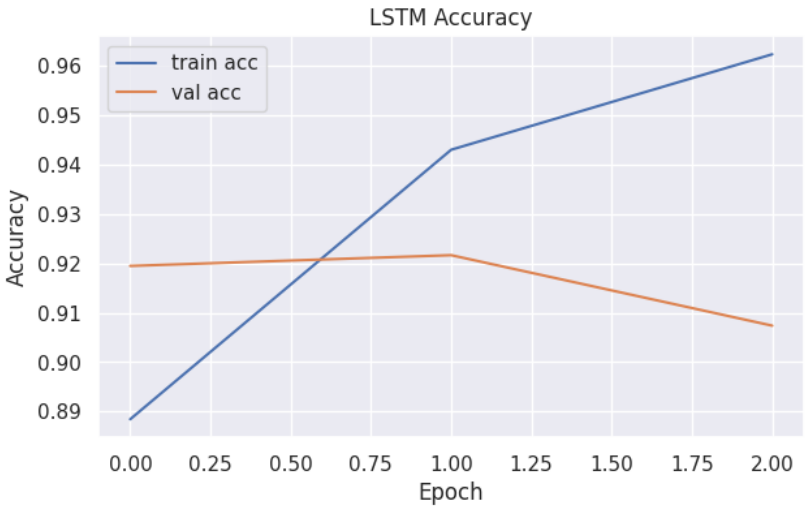


FIGURE 4.4 – Courbe d'apprentissage du modèle LSTM

surapprentissage et justifie l'usage d'*early stopping* ou d'une régularisation plus forte.

4.5 Modèle BERT

Le modèle DistilBERT appartient à la famille des architectures *Transformers* et repose sur le principe de l'auto-attention, permettant de capturer les relations contextuelles entre les mots indépendamment de leur position dans la phrase. Contrairement aux modèles séquentiels classiques, cette architecture offre une représentation bidirectionnelle du texte, ce qui améliore la compréhension sémantique des avis clients.

Dans ce projet, le modèle DistilBERT, version allégée de BERT, a été choisi afin de réduire le coût computationnel tout en conservant de bonnes performances. Un *fine-tuning* supervisé a été réalisé sur un sous-ensemble du jeu de données Amazon Review Polarity, en adaptant la couche de classification finale à la tâche de polarité binaire.

Les résultats obtenus montrent que DistilBERT fournit une excellente capacité de généralisation, notamment sur les avis complexes ou ambigus, au prix d'un temps d'entraînement et d'inférence plus élevé que les approches classiques. Ce compromis entre performance et coût rend ce modèle particulièrement adapté aux applications nécessitant une analyse fine du langage naturel.

Chapitre 5

Résultats et Analyse

Modèle	**Accuracy**
TF-IDF + LogReg	0.9189
LSTM	**0.9596**
BERT (DistilBERT)	0.9463

TABLE 5.1 – Comparaison des performances des modèles

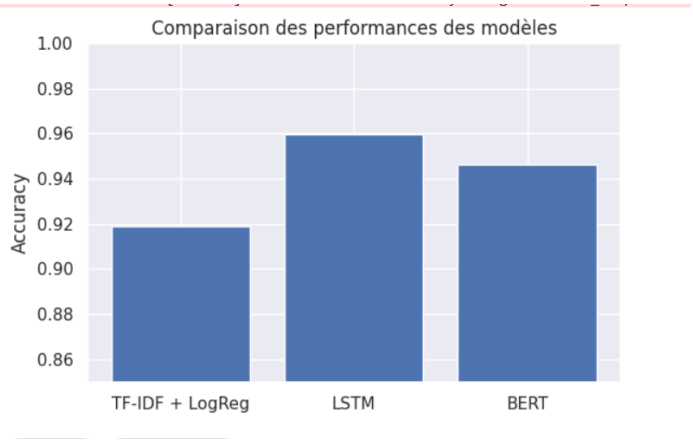


FIGURE 5.1 – Comparaison visuelle des performances

Les résultats montrent que le LSTM atteint la meilleure précision numérique sur l'échantillon évalué. Le modèle BERT reste très compétitif et est généralement plus robuste aux formulations complexes. La baseline TF-IDF conserve un excellent compromis performance/coût.

Chapitre 6

Discussion

Le choix du modèle dépend des contraintes d'utilisation. TF-IDF est adapté aux environnements à ressources limitées et à forte volumétrie. Le LSTM capture l'ordre des mots mais peut surapprendre sans régularisation. BERT est recommandé lorsque la robustesse et la compréhension contextuelle sont prioritaires, malgré un coût computationnel plus élevé.

Chapitre 7

Conclusion et Perspectives

7.1 Conclusion

Ce projet a permis de construire un pipeline NLP complet pour l'analyse de sentiments sur des avis clients et de comparer plusieurs familles de modèles. Les résultats confirment l'apport des approches profondes, tout en mettant en évidence les compromis entre performance et coût.

7.2 Perspectives

Plusieurs axes d'amélioration peuvent être envisagés afin d'enrichir et de généraliser le système proposé. Tout d'abord, l'intégration explicite d'une classe neutre permettrait de mieux représenter les avis exprimant une opinion mitigée ou descriptive, souvent présents dans les retours clients réels. Cette extension améliorerait la finesse de l'analyse des sentiments.

Par ailleurs, une extension multilingue du système, notamment à l'aide de modèles de type BERT multilingue, offrirait la possibilité d'analyser des avis rédigés dans différentes langues et d'élargir le champ d'application du modèle à des contextes internationaux.

Enfin, le déploiement du modèle sous forme d'API ou d'application web interactive, par exemple à l'aide de Streamlit, faciliterait son intégration dans des environnements industriels et permettrait une utilisation en temps réel par des utilisateurs non techniques.

Bibliographie

[1] J. McAuley, J. Leskovec, *Hidden factors and hidden topics : understanding rating dimensions with review text*, RecSys, 2013.

[2] X. Zhang, J. Zhao, Y. LeCun, *Character-level Convolutional Networks for Text Classification*, NeurIPS, 2015.

[3] J. Devlin et al., *BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding*, NAACL, 2018.